Caracterizando a atividade de code review em repositórios populares do GitHub

Carlos Henrique Neimar, João Victor Temponi Daltro de Castro

1 Introdução

1.1 O paradigma e os desafios do code review em projetos de código aberto

A prática de code review tornou-se um pilar nos processos de desenvolvimento ágeis. Em sua essência, ela consiste na interação entre desenvolvedores e revisores com o objetivo de inspecionar o código produzido antes de sua integração à base principal do projeto. Este processo é fundamental para garantir a qualidade do código que é integrado, além de ser uma estratégia eficaz para evitar a introdução de novos defeitos no software.

No ecossistema de software de código aberto (open source), especialmente nos projetos hospedados na plataforma GitHub, as atividades de code review são estruturadas em torno da avaliação de contribuições submetidas por meio de Pull Requests (PRs). Para que uma nova contribuição de código seja incorporada à branch principal, é necessário que um colaborador do projeto avalie e discuta a solicitação, que ao final pode ser aprovada (merged) ou rejeitada (closed). Frequentemente, ferramentas de verificação estática e de integração contínua realizam uma análise preliminar para assegurar a conformidade com estilos de programação e padrões definidos pela organização. É neste cenário que se insere o presente estudo, cujo objetivo é analisar a atividade de code review para identificar variáveis que influenciam na aceitação ou rejeição de um PR.

1.2 Quantificando o Processo de Code Review com Métricas de Pull Request

Para avaliar objetivamente o processo de revisão, este estudo utilizou um conjunto de métricas que quantificam dimensões distintas de um Pull Request:

- **Tamanho**: Mede a magnitude da contribuição. É quantificado pelo número de arquivos modificados e pelo total de linhas de código adicionadas e removidas.

- **Tempo de Análise**: Representa o tempo que um PR permaneceu em discussão. É

definido como o intervalo entre a data de criação do PR e a data de sua última atividade (seja o merge ou o fechamento).

- **Descrição**: Avalia o esforço do contribuidor em contextualizar sua mudança. É mensurado pelo número de caracteres presentes no corpo da descrição do PR.

- **Interações**: Captura o nível de engajamento e discussão gerado pelo PR. É medido pelo número de participantes envolvidos na discussão e pelo número total de comentários.

1.3 Questões de Pesquisa e Hipóteses

Para guiar esta investigação, foram estabelecidas oito questões de pesquisa (QP), divididas em duas dimensões principais. Cada uma é acompanhada por uma hipótese nula (H0), que assume a ausência de relação, e uma hipótese alternativa (H1), que propõe a existência de tal relação.

A. Relação com o Feedback Final das Revisões (Status do PR):

- QP01: Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
  - H01: O tamanho de um PR não possui correlação estatisticamente significativa com seu status final (merged/closed).
  - H11: O tamanho de um PR possui correlação estatisticamente significativa com seu status final.

- QP02: Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?
  - H02: O tempo de análise de um PR não possui correlação estatisticamente significativa com seu status final.
  - H12: O tempo de análise de um PR possui correlação estatisticamente significativa com seu status final.

- QP03: Qual a relação entre a descrição dos PRs e o feedback final das revisões?
  - H03: A qualidade da descrição de um PR não possui correlação estatisticamente significativa com seu status final.
  - H13: A qualidade da descrição de um PR possui correlação estatisticamente significativa com seu status final.

- QP04: Qual a relação entre as interações nos PRs e o feedback final das revisões?
    - H04: O nível de interação em um PR não possui correlação estatisticamente significativa com seu status final.
    - H14: O nível de interação em um PR possui correlação estatisticamente significativa com seu status final.

B. Relação com o Número de Revisões:

- QP05: Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
    - H05: O tamanho de um PR não possui correlação estatisticamente significativa com o número de revisões que recebe.
    - H15: O tamanho de um PR possui correlação estatisticamente significativa com o número de revisões que recebe.

- QP06: Qual a relação entre o tempo de análise dos PRs e o número de revisões realizadas?
    - H06: O tempo de análise de um PR não possui correlação estatisticamente significativa com o número de revisões que recebe.
    - H16: O tempo de análise de um PR possui correlação estatisticamente significativa com o número de revisões que recebe.

- QP07: Qual a relação entre a descrição dos PRs e o número de revisões realizadas?
    - H07: A qualidade da descrição de um PR não possui correlação estatisticamente significativa com o número de revisões que recebe?
    - H17: A qualidade da descrição de um PR possui correlação estatisticamente significativa com o número de revisões que recebe.

- QP08: Qual a relação entre as interações nos PRs e o número de revisões realizadas?
    - H08: O nível de interação em um PR não possui correlação estatisticamente significativa com o número de revisões que recebe.
    - H18: O nível de interação em um PR possui correlação estatisticamente significativa com o número de revisões que recebe.

2. Metodologia

2.1 Pesquisa e Amostra

O dataset deste estudo foi composto por Pull Requests extraídos de repositórios de software no GitHub que atenderam aos seguintes critérios de seleção:

1. Critérios para Repositórios:
    - Popularidade: Foram considerados os 200 repositórios mais populares da plataforma, com base no número de estrelas.
    - Volume de Atividade: Os repositórios selecionados possuíam um histórico de, no mínimo, 100 Pull Requests com status MERGED ou CLOSED.
2. Critérios para Pull Requests:

Além dos critérios para os repositórios, os Pull Requests individuais foram filtrados para garantir que passaram por um processo de revisão humano e significativo:

- Status: Apenas PRs com status MERGED ou CLOSED foram incluídos na análise.
- Existência de Revisão: Cada PR deveria ter recebido pelo menos uma revisão.
- Filtro de Automação: Para remover PRs possivelmente revisados por bots ou ferramentas automáticas, a análise considerou apenas aqueles cujo tempo entre a criação e o fechamento (ou merge) foi maior que uma hora.

2.2 Coleta e Pré-processamento de Dados

A coleta de dados foi realizada de forma automatizada através da criação de um script. Este script utilizou a API do GitHub para:

- Identificar a lista de repositórios que se enquadravam nos critérios de popularidade e volume.
- Iterar sobre os PRs de cada repositório, aplicando os filtros de status, número de revisões e tempo de análise.
- Para cada PR válido, extrair as métricas definidas na seção 1.2: tamanho (arquivos, linhas adicionadas/removidas), tempo de análise, descrição (número de caracteres) e interações (participantes e comentários).

Janela Temporal e Limitações da Extração:

Para garantir a qualidade e representatividade dos dados, a extração foi limitada aos Pull Requests criados nos últimos 5 anos a partir da data de coleta. Além disso, foi estabelecido um limite máximo de 4.000 PRs por repositório. Essas restrições foram implementadas para evitar que os dados do dataset ficassem percentualmente concentrados em poucos repositórios de altíssima atividade, o que poderia enviesar a análise e comprometer a generalização dos resultados.

Os dados coletados foram consolidados em um dataset único, que serviu de base para a fase de análise estatística.

2.3 Método de Análise Estatística

A análise dos dados foi conduzida em duas etapas principais:

- Estatística Descritiva: Para caracterizar a amostra, os dados foram sumarizados utilizando a mediana como medida de tendência central para cada métrica coletada. Esta abordagem foi escolhida para mitigar o efeito de valores extremos (outliers), comuns em dados de repositórios de software.
- Análise Correlacional: Para investigar as questões de pesquisa, foi utilizado o coeficiente de correlação de Spearman, escolhido devido à natureza não-normal da distribuição dos dados. Todas as hipóteses foram avaliadas considerando um nível de significância (α) de 0.05.

2.4 Desafios da Coleta e Análise de Dados

O processo de extração e preparação dos dados apresentou desafios significativos que exigiram ajustes metodológicos:

- Estratégia Inicial de Amostragem: A primeira tentativa de extração utilizou uma estratégia conservadora, coletando apenas 300 PRs dos últimos 2 anos de cada repositório. Esta abordagem resultou em um dataset com apenas 5.000 linhas, que se mostrou insuficiente para análises robustas. Mais importante, essa estratégia ignorava uma quantidade significativa de dados históricos relevantes, potencialmente introduzindo viés temporal na análise. Diante dessa limitação, optou-se por refazer completamente a extração com uma janela temporal mais ampla (5 anos) e um limite maior de PRs por repositório (4.000), garantindo maior representatividade dos dados.
- Curadoria da Amostra: A implementação inicial do script de coleta continha um erro de lógica que resultou em uma amostra menor que a planejada. O script analisava uma lista de 200 repositórios populares e, em seguida, selecionava apenas os que eram válidos dentro desse grupo, o que resultava em aproximadamente 180 repositórios. A lógica foi ajustada para garantir a busca contínua até que 200 repositórios que atendessem a todos os critérios fossem efetivamente coletados.
- Custo Computacional e Eficiência da API: A primeira versão do script utilizava a API REST do GitHub. Essa abordagem se mostrou ineficiente, resultando em um tempo de execução excessivamente longo devido ao alto volume de requisições necessárias. Para otimizar o processo, a implementação foi migrada para a API GraphQL, permitindo a construção de consultas mais específicas que retornavam apenas os dados necessários em uma única requisição, reduzindo drasticamente o tempo de coleta.
- Gestão do Volume de Dados: A estratégia inicial consistia em salvar todos os dados brutos coletados e aplicar os filtros posteriormente. No entanto, essa abordagem gerou

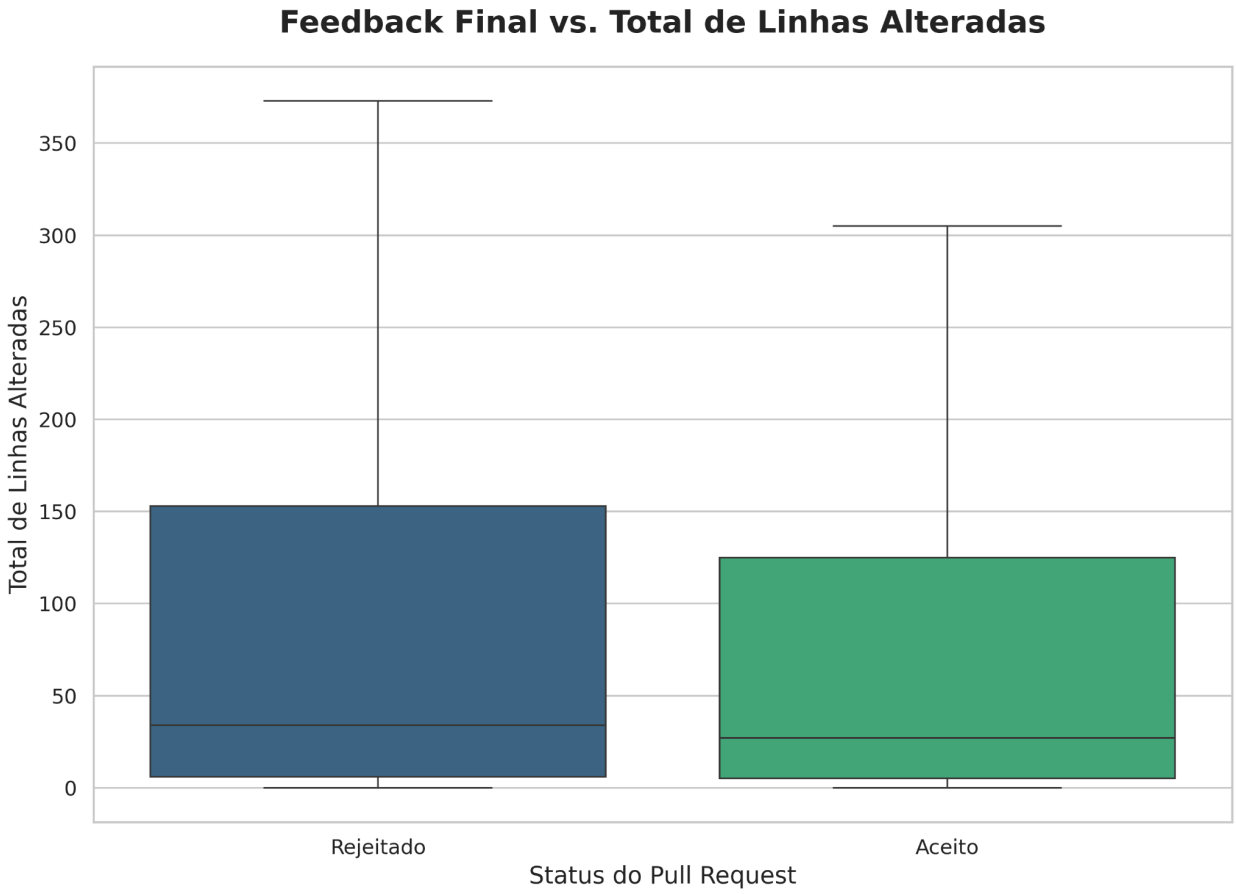
arquivos de dados de tamanho massivo, tornando a manipulação e a filtragem computacionalmente custosas e lentas. O processo foi refinado para que os filtros fossem aplicados em tempo de execução, diretamente durante a coleta, garantindo que apenas os dados relevantes fossem salvos no dataset final, otimizando o armazenamento e o processamento subsequente.

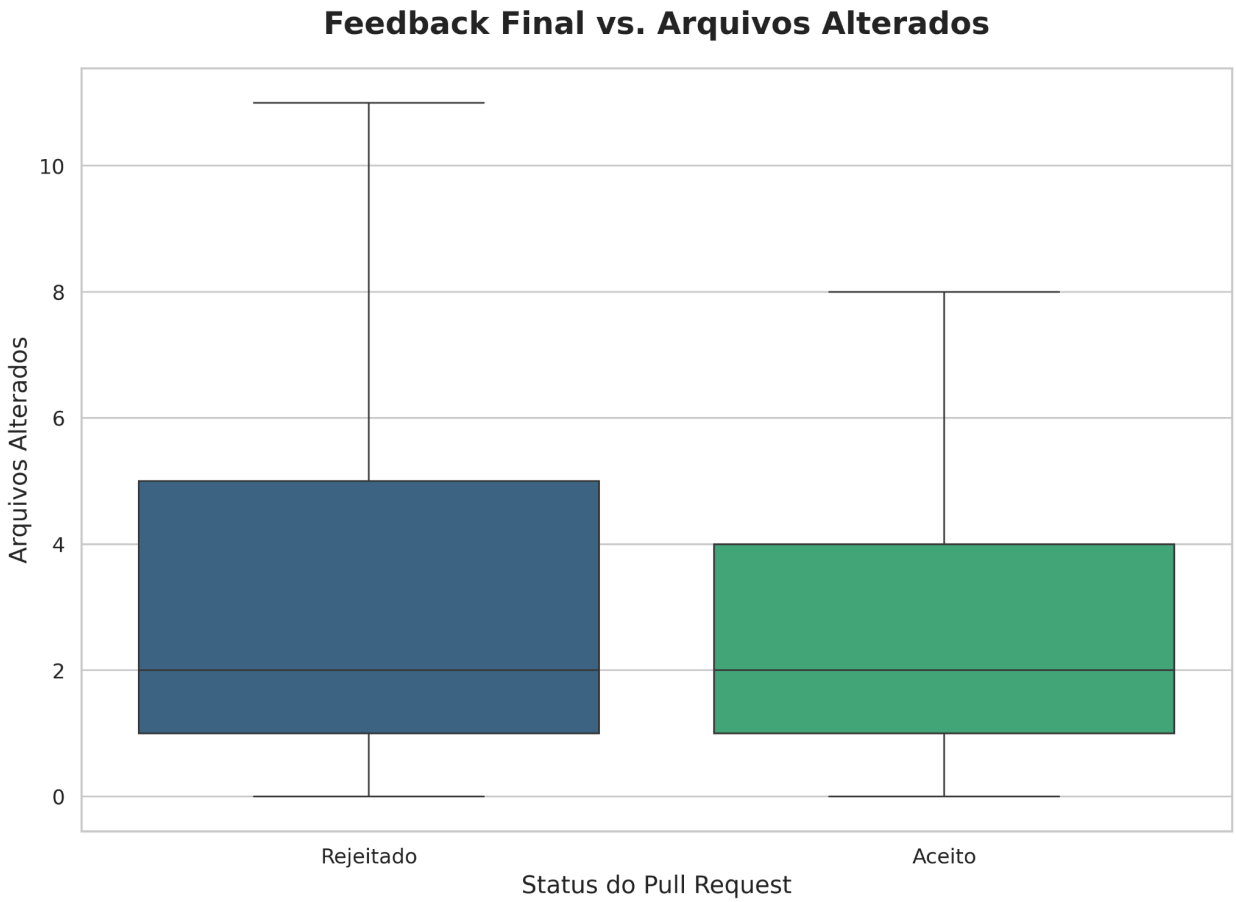
3 Resultados e Análise

A análise dos dados foi estruturada para responder individualmente a cada uma das oito questões de pesquisa, utilizando os gráficos gerados para visualizar as relações entre as métricas dos Pull Requests (PRs).

QP01: Relação entre Tamanho e Feedback Final

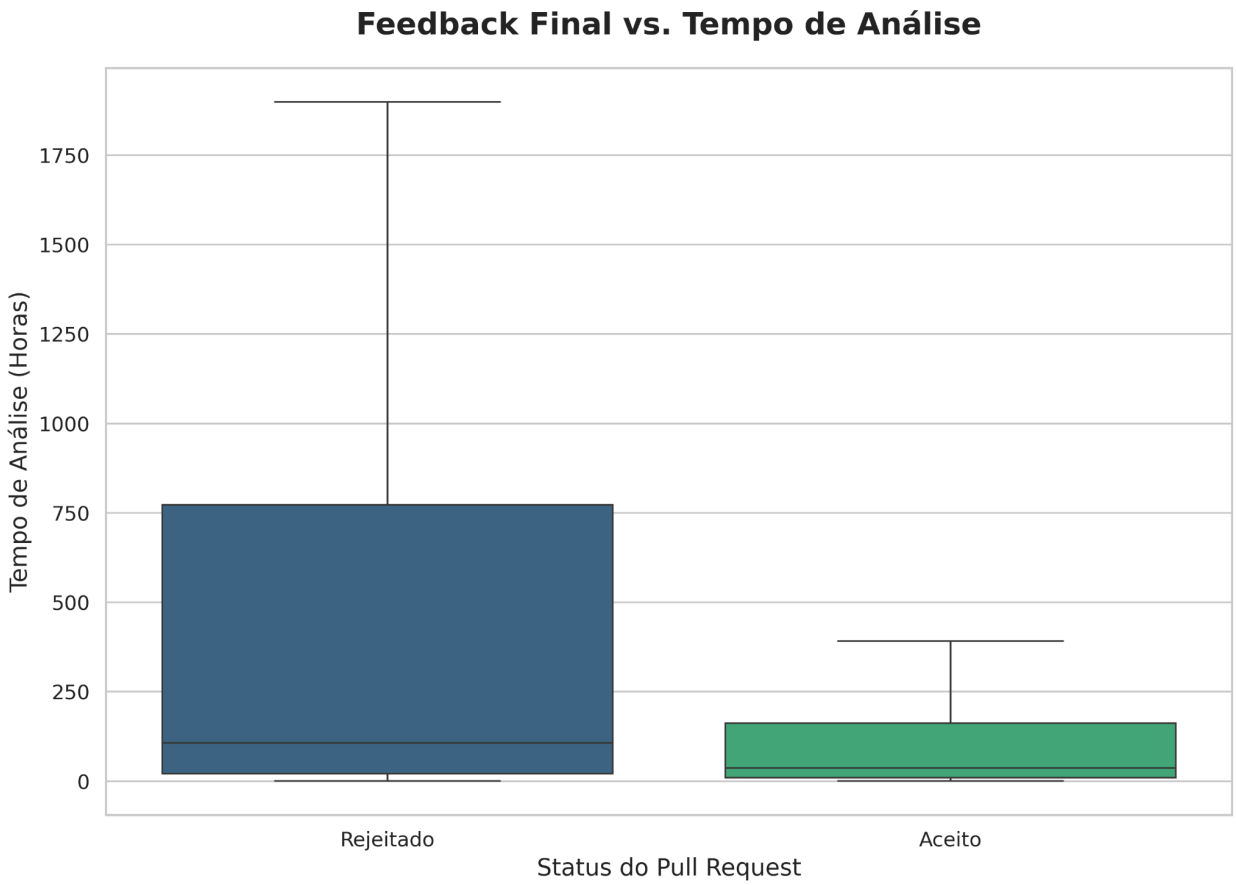
A análise da relação entre o tamanho de um PR e seu resultado (aceito ou rejeitado) apresentou resultados mistos. No gráfico que compara o total de linhas alteradas, a mediana para os PRs rejeitados é visivelmente superior à dos PRs aceitos. A distribuição dos dados para PRs rejeitados também é mais ampla, com o quartil superior e o limite máximo atingindo valores mais altos. Em contrapartida, ao analisar o número de arquivos alterados, a mediana é a mesma para ambos os status (aceito e rejeitado). As distribuições neste caso são bastante semelhantes. Dada a evidência forte apenas para o número de linhas, a hipótese nula H01 é rejeitada, concluindo-se que PRs com um número maior de linhas alteradas têm maior propensão a serem rejeitados.


Feedback Final vs. Total de Linhas Alteradas
Total de Linhas Alteradas
350
300
250
200
150
100
50
0
Rejeitado
Aceito
Status do Pull Request



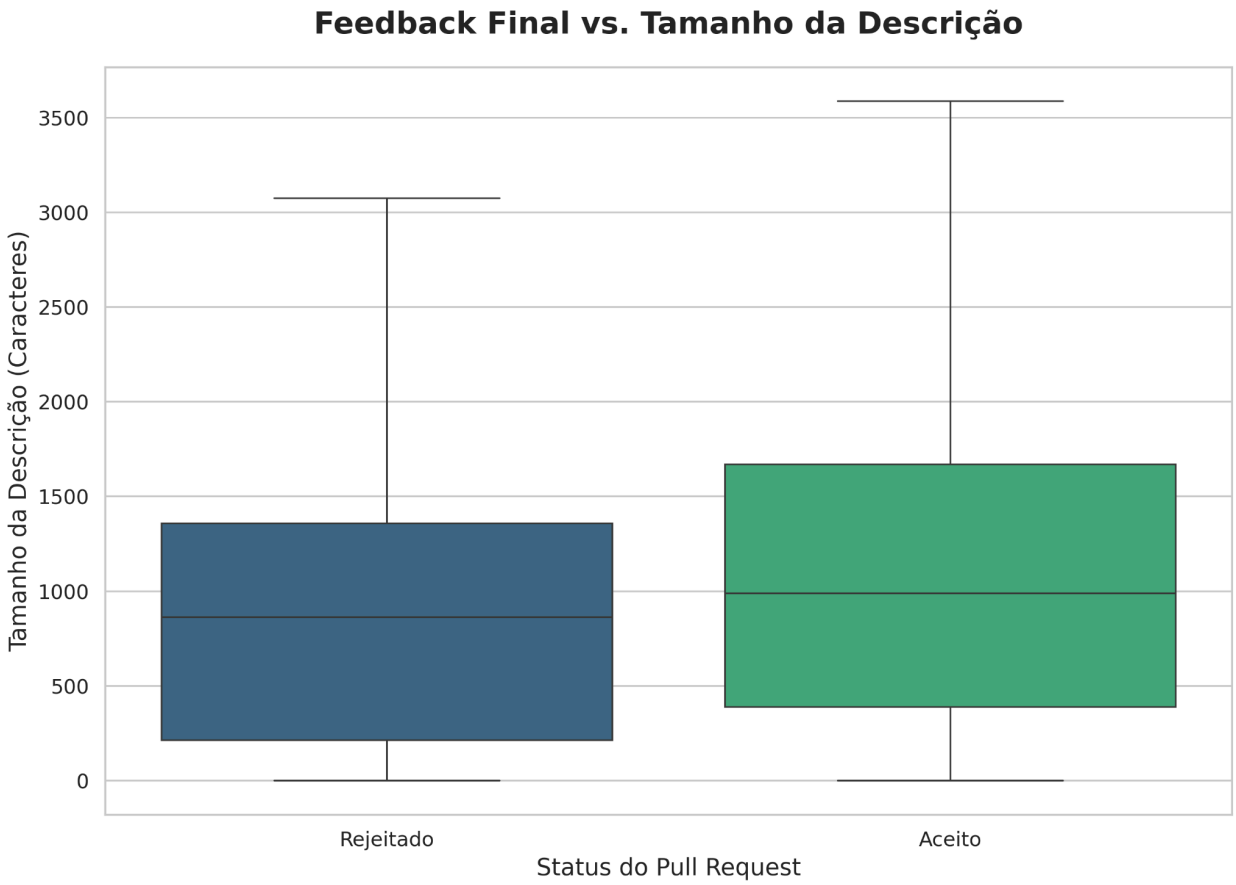
QP02: Relação entre Tempo de Análise e Feedback Final

O tempo de análise demonstrou ser um forte preditor do resultado de um PR. O gráfico de boxplot mostra uma diferença drástica entre os dois grupos. A mediana do tempo para PRs rejeitados é muitas vezes superior à dos PRs aceitos, e a dispersão dos dados (a "caixa" do boxplot) é consideravelmente maior para o grupo dos rejeitados. Com base nesta forte evidência visual, a hipótese nula H02 é rejeitada.



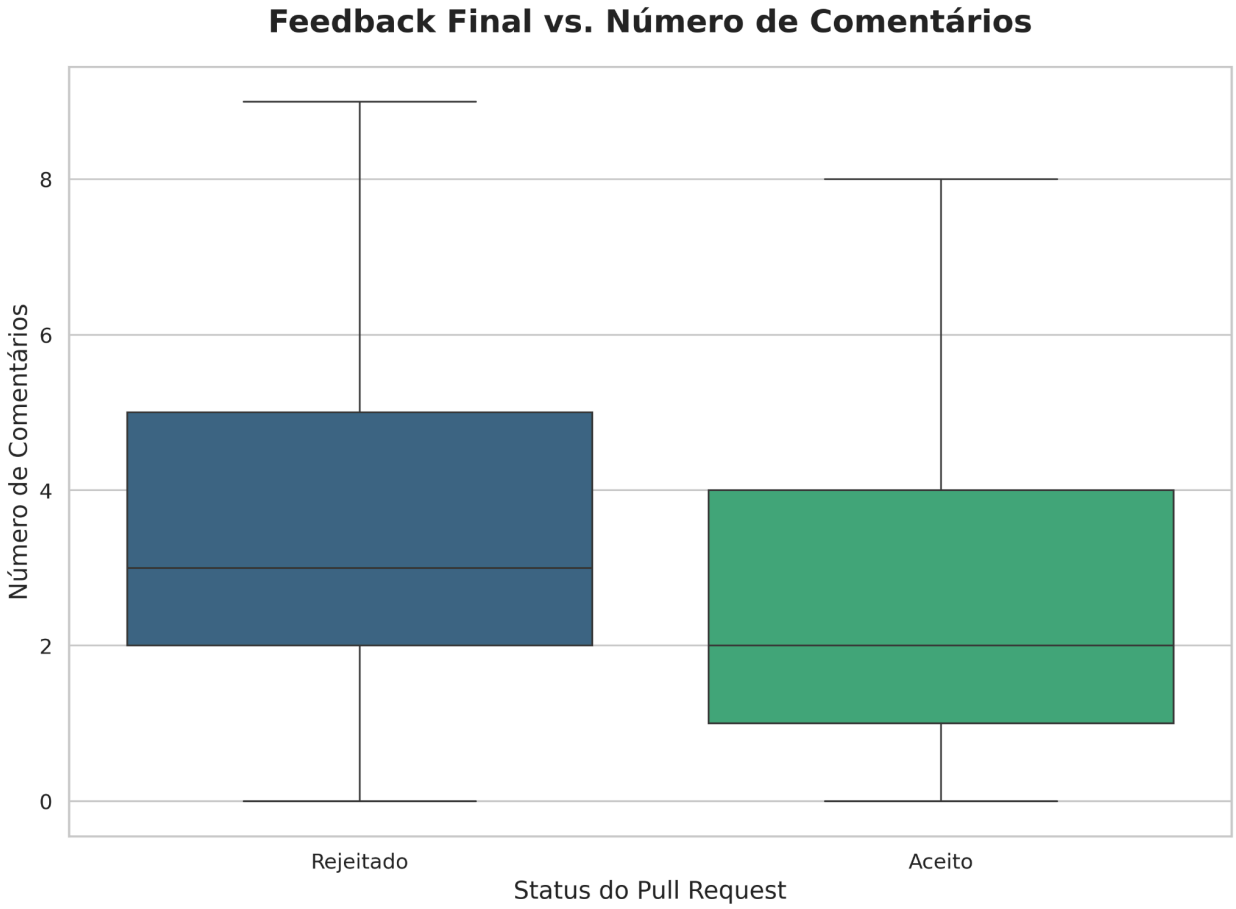
QP03: Relação entre Descrição e Feedback Final

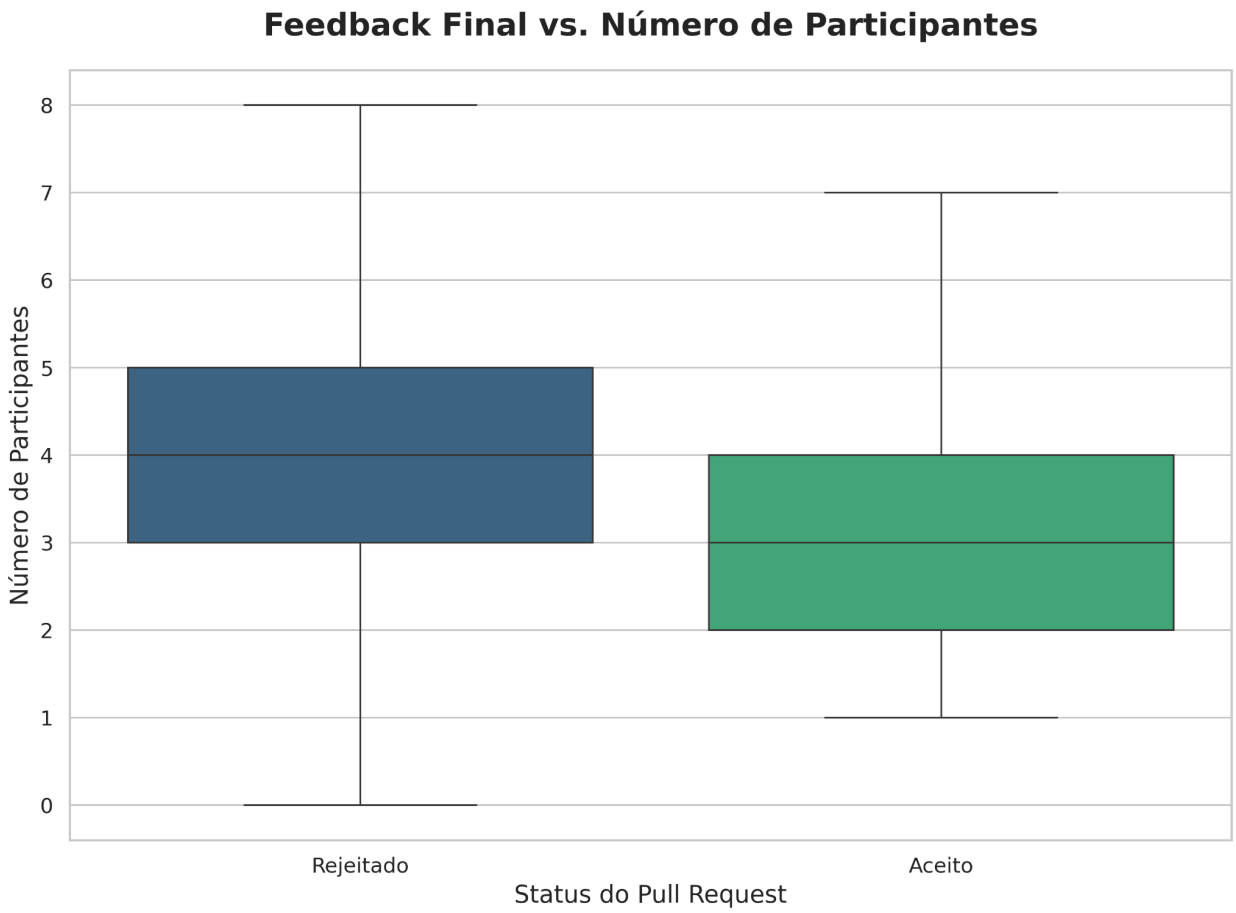
A análise da descrição do PR sugere que a comunicação clara é um fator relevante para o sucesso de uma contribuição. A mediana do tamanho da descrição (em caracteres) é visivelmente maior nos PRs que foram aceitos em comparação com os que foram rejeitados. A distribuição para PRs aceitos também se estende a valores mais altos. Portanto, a hipótese nula H03 é rejeitada.



QP04: Relação entre Interações e Feedback Final

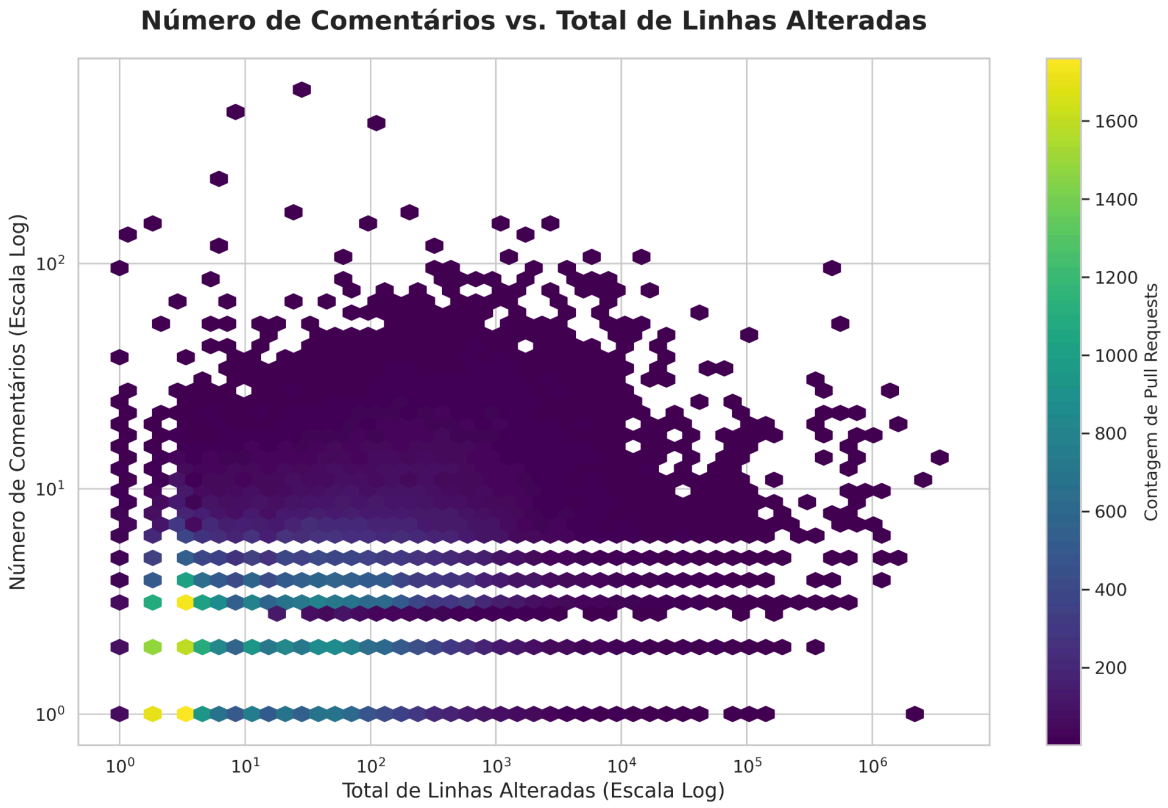
Um maior volume de interações mostrou estar associado à rejeição de um PR. A mediana do número de comentários é maior para os PRs rejeitados. Da mesma forma, a mediana do número de participantes também é superior no grupo de PRs rejeitados (mediana de 4) em comparação com os aceitos (mediana de 3). Ambos os resultados indicam que um debate mais intenso e o envolvimento de mais pessoas estão correlacionados com um desfecho negativo. Assim, a hipótese nula H04 é rejeitada.


Feedback Final vs. Número de Comentários
Número de Comentários
0
2
4
6
8
Rejeitado
Aceito
Status do Pull Request

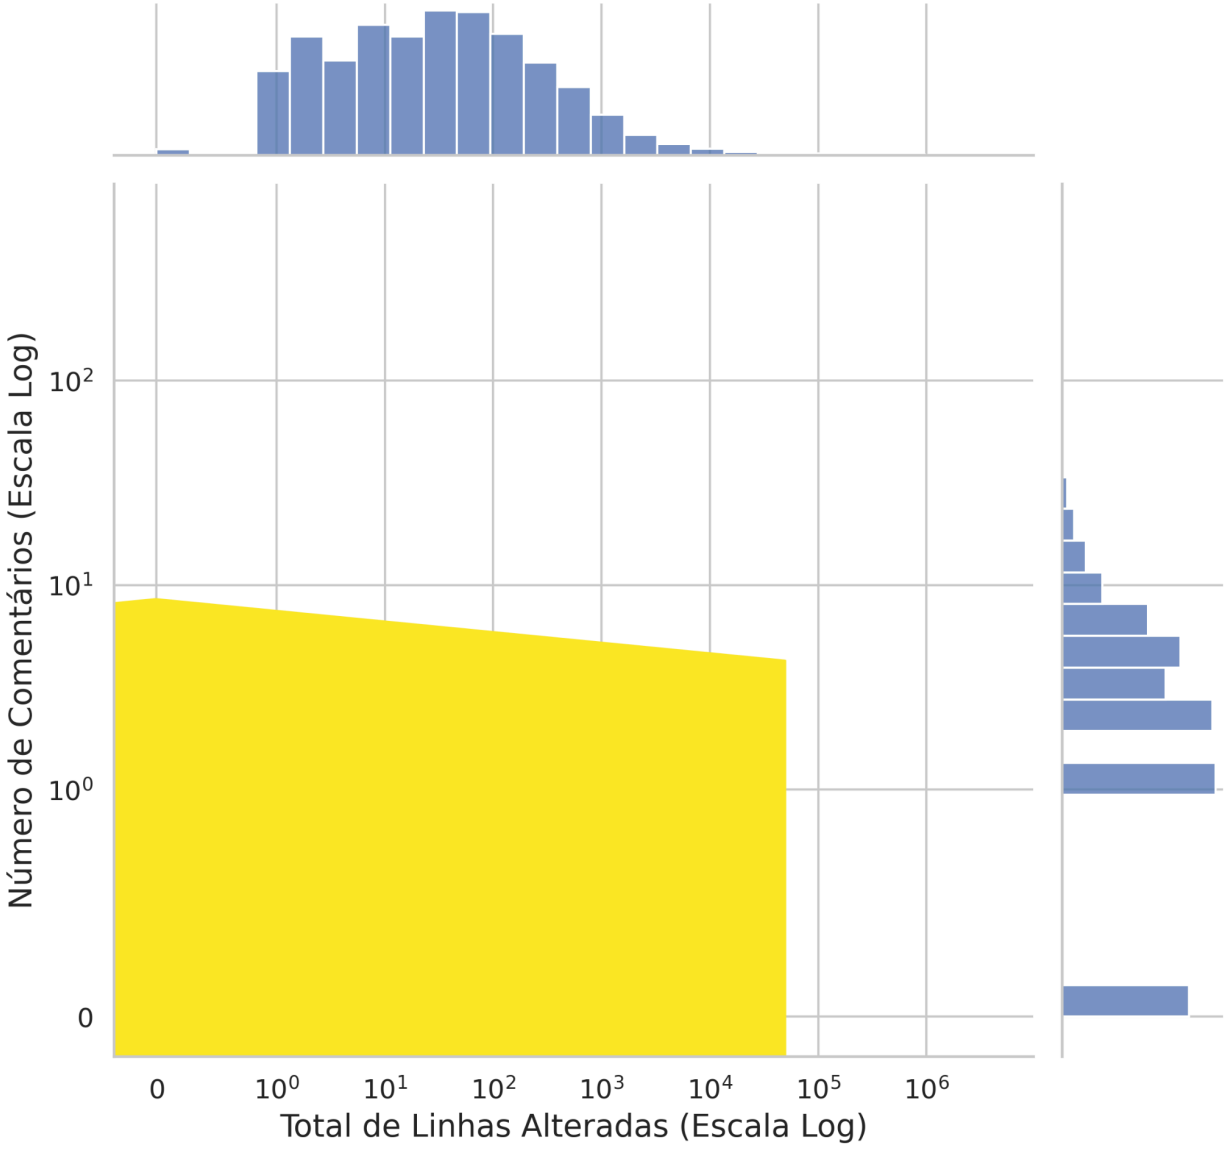


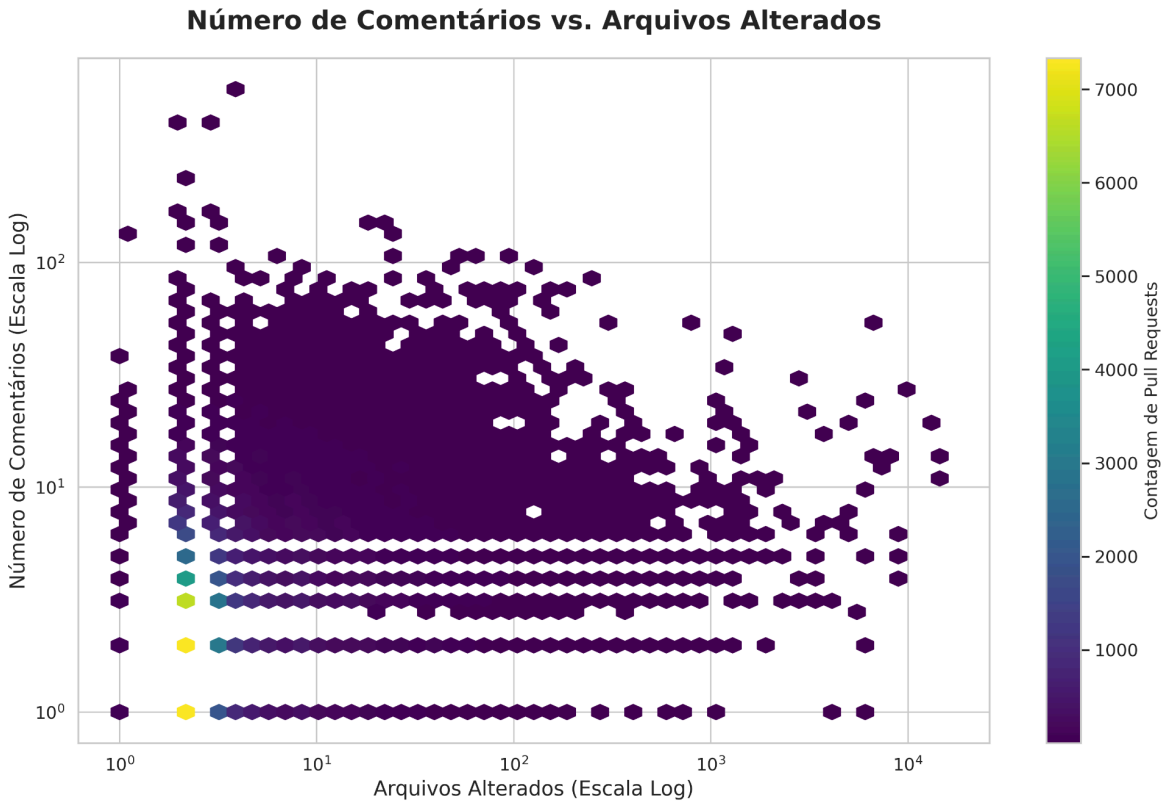
QP05: Relação entre Tamanho e Número de Comentários

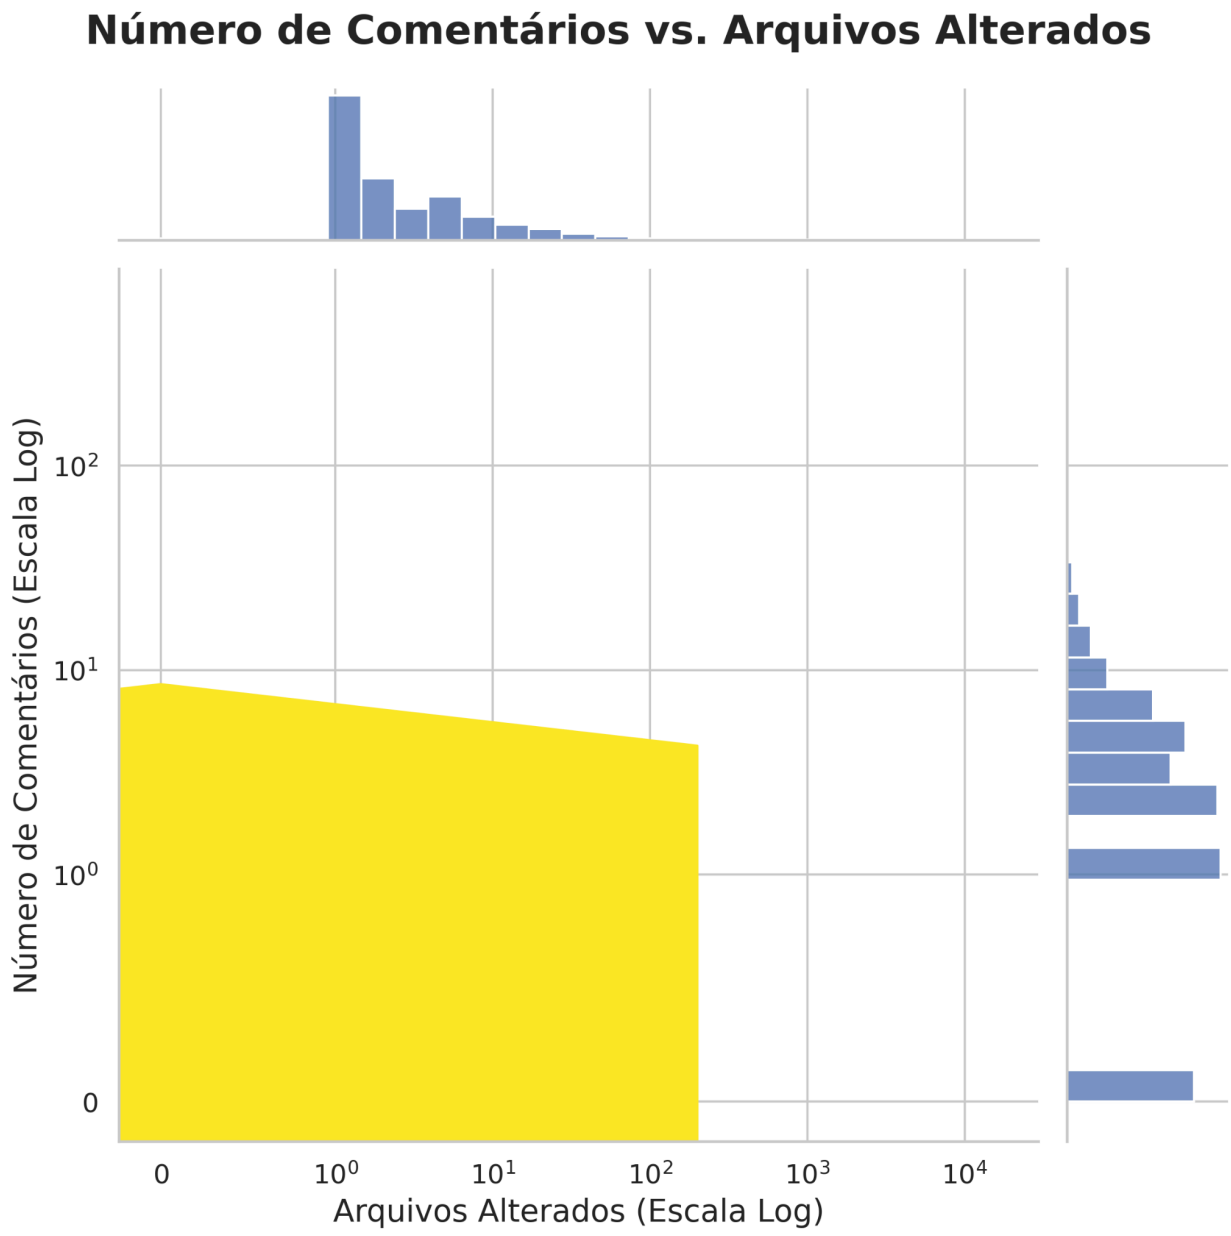
Os gráficos indicam que o tamanho de um PR está positivamente correlacionado com a quantidade de debate que ele gera. O gráfico de dispersão entre o total de linhas alteradas e o número de comentários mostra uma tendência positiva. Similarmente, o gráfico hexagonal entre o número de arquivos alterados e os comentários mostra que a maior concentração de PRs com muitos comentários ocorre quando há um número maior de arquivos. Com base nisso, a hipótese nula H05 é rejeitada.


Número de Comentários vs. Total de Linhas Alteradas
Número de Comentários (Escala Log)
Total de Linhas Alteradas (Escala Log)
Contagem de Pull Requests
10^0
10^1
10^2
10^3
10^4
10^5
10^6
200
400
600
800
1000
1200
1400
1600

Número de Comentários vs. Total de Linhas Alteradas

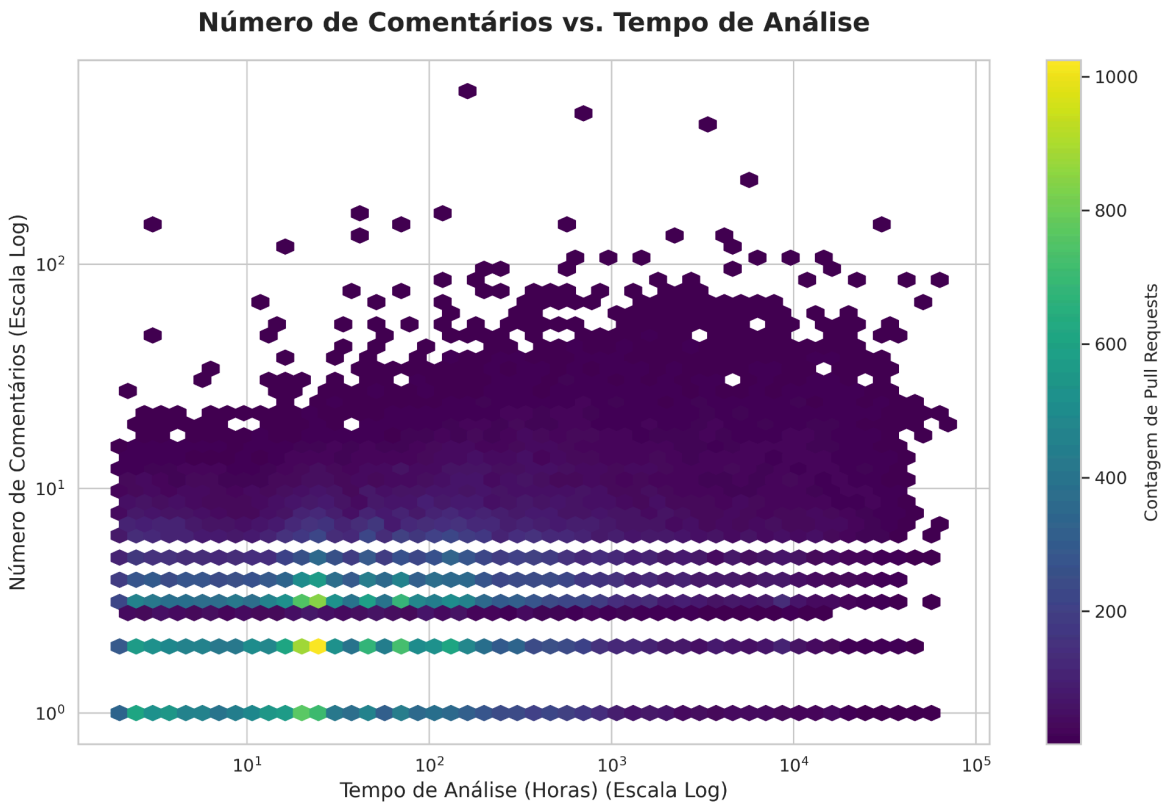


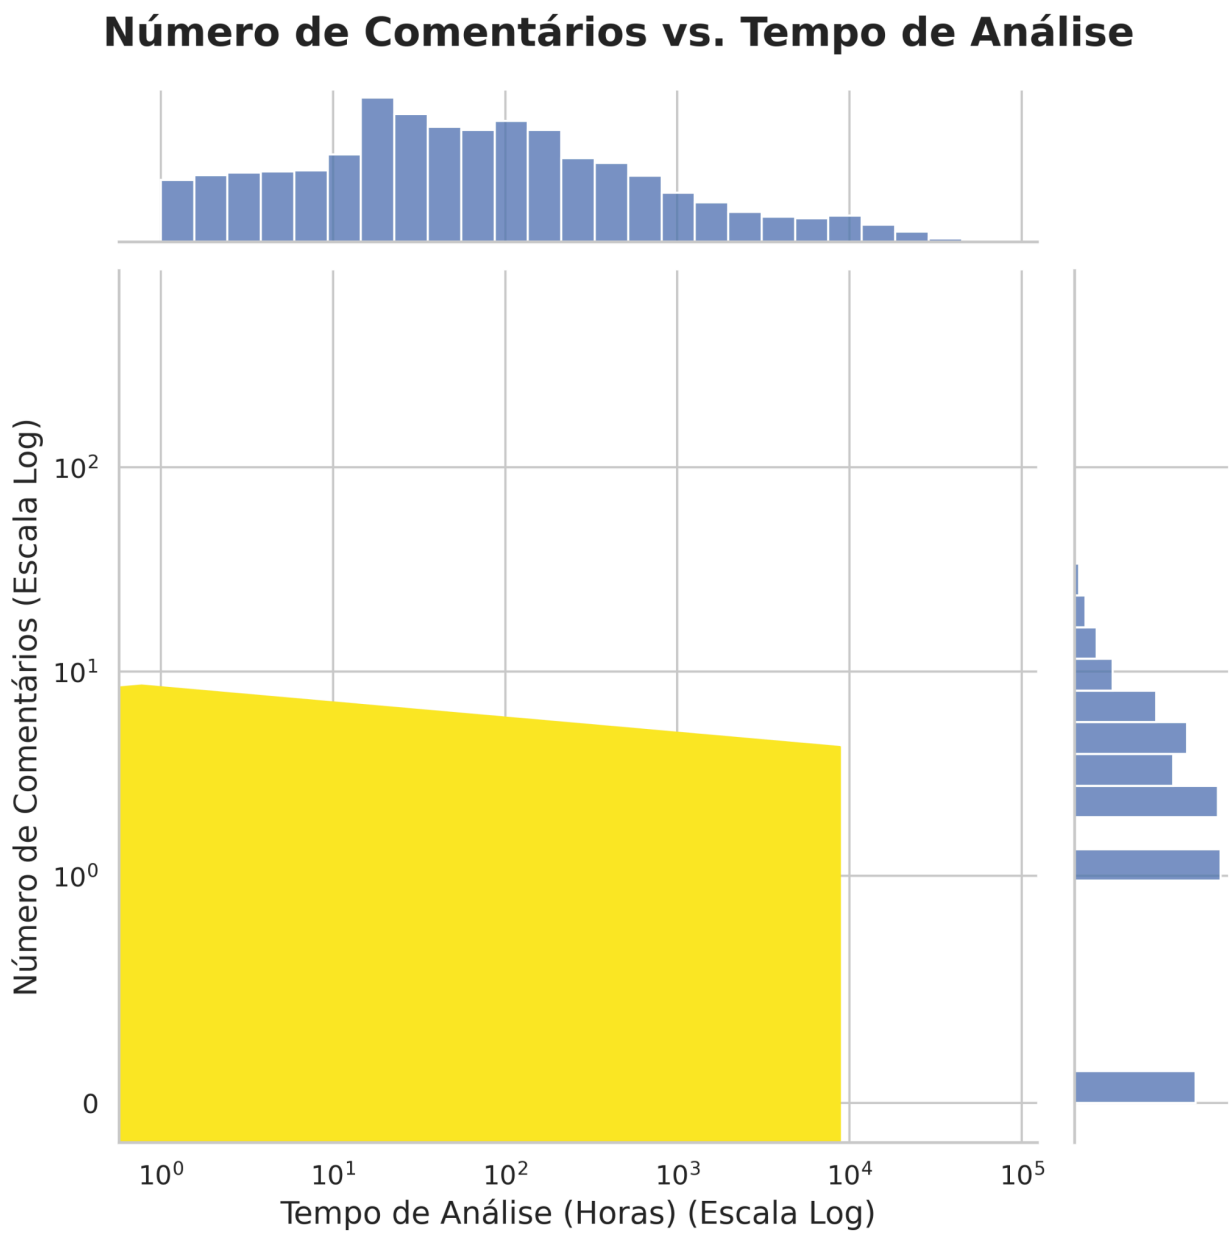

Número de Comentários vs. Arquivos Alterados
Número de Comentários (Escala Log)
Arquivos Alterados (Escala Log)
Contagem de Pull Requests
10^0
10^1
10^2
10^3
10^4
7000
6000
5000
4000
3000
2000
1000



QP06: Relação entre Tempo de Análise e Número de Comentários

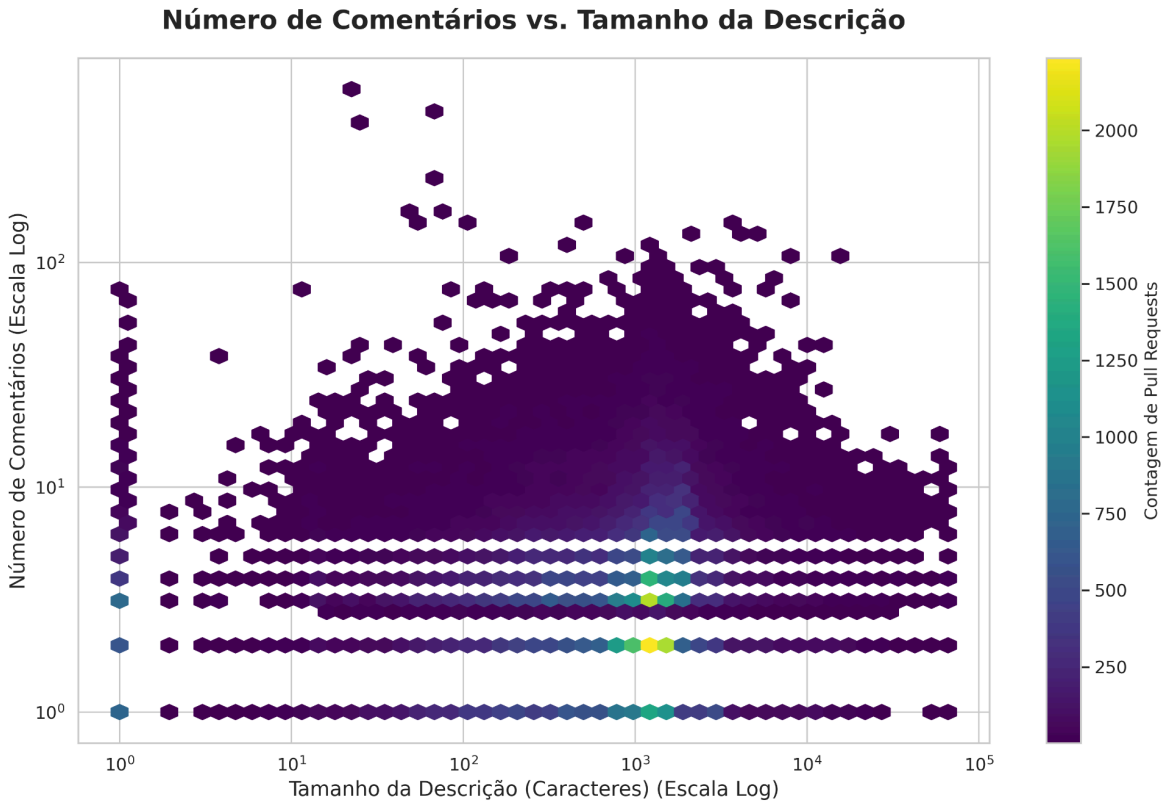
Existe uma clara correlação positiva entre o tempo em que um PR permanece aberto e o número de comentários que ele acumula. O gráfico de dispersão mostra que, à medida que o tempo de análise aumenta (eixo x), os valores no eixo do número de comentários (eixo y) também tendem a aumentar. A hipótese nula H06 é, portanto, rejeitada.

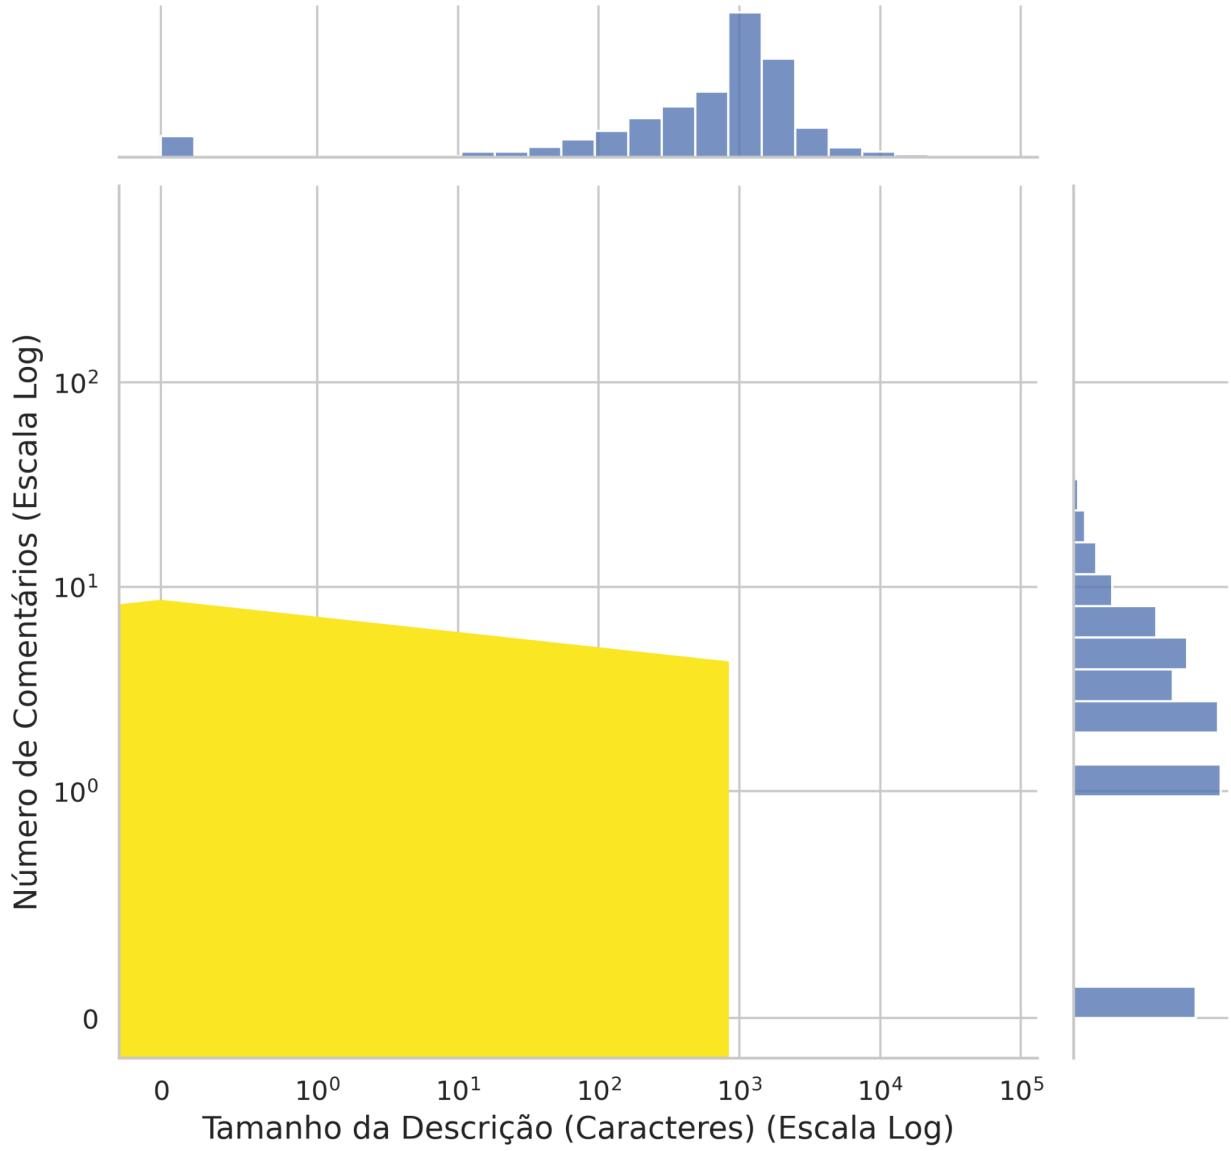

Número de Comentários vs. Tempo de Análise
Número de Comentários (Escala Log)
10^2
10^1
10^0
10^1
10^2
10^3
10^4
10^5
Tempo de Análise (Horas) (Escala Log)
1000
800
600
400
200
Contagem de Pull Requests



QP07: Relação entre Descrição e Número de Comentários

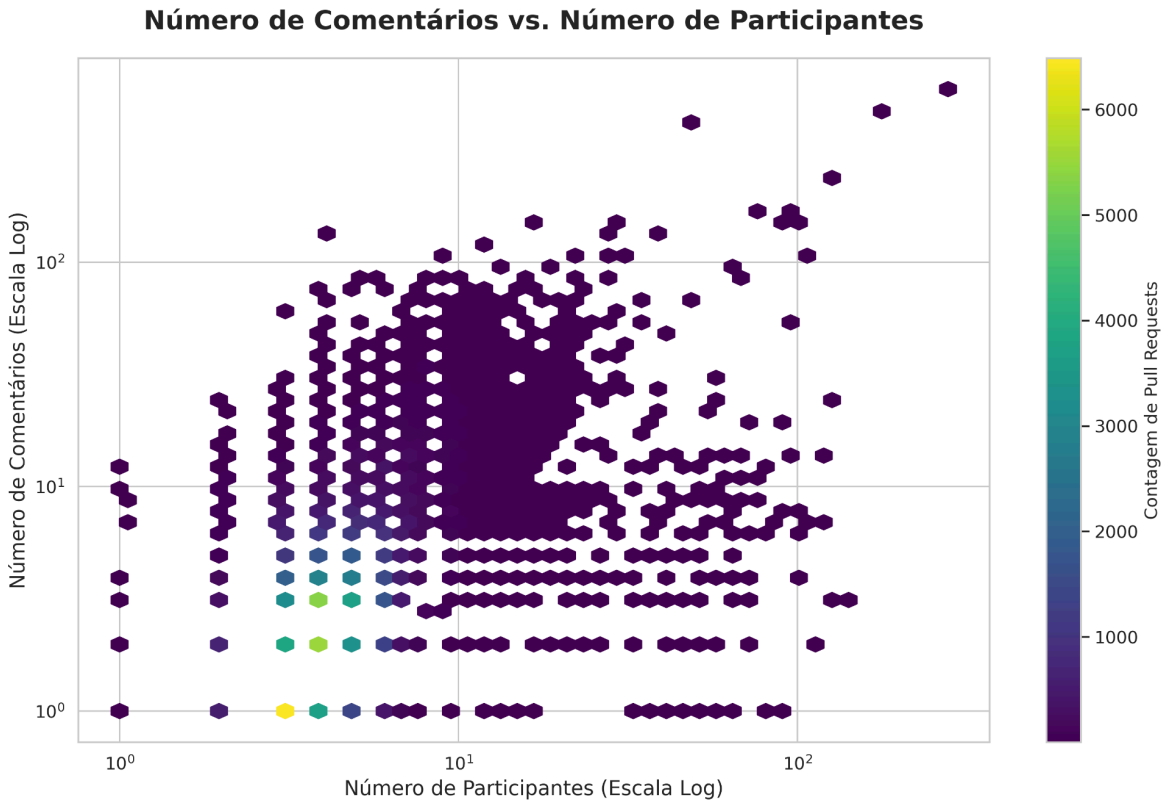
A relação entre o tamanho da descrição e o número de comentários é de uma correlação positiva, embora mais fraca que as outras. O gráfico hexagonal mostra que a maior densidade de comentários ocorre para PRs com descrições de tamanho intermediário (entre 10^2 e 10^3 caracteres). PRs com descrições muito curtas raramente acumulam muitos comentários. Desta forma, a hipótese nula H07 é rejeitada.

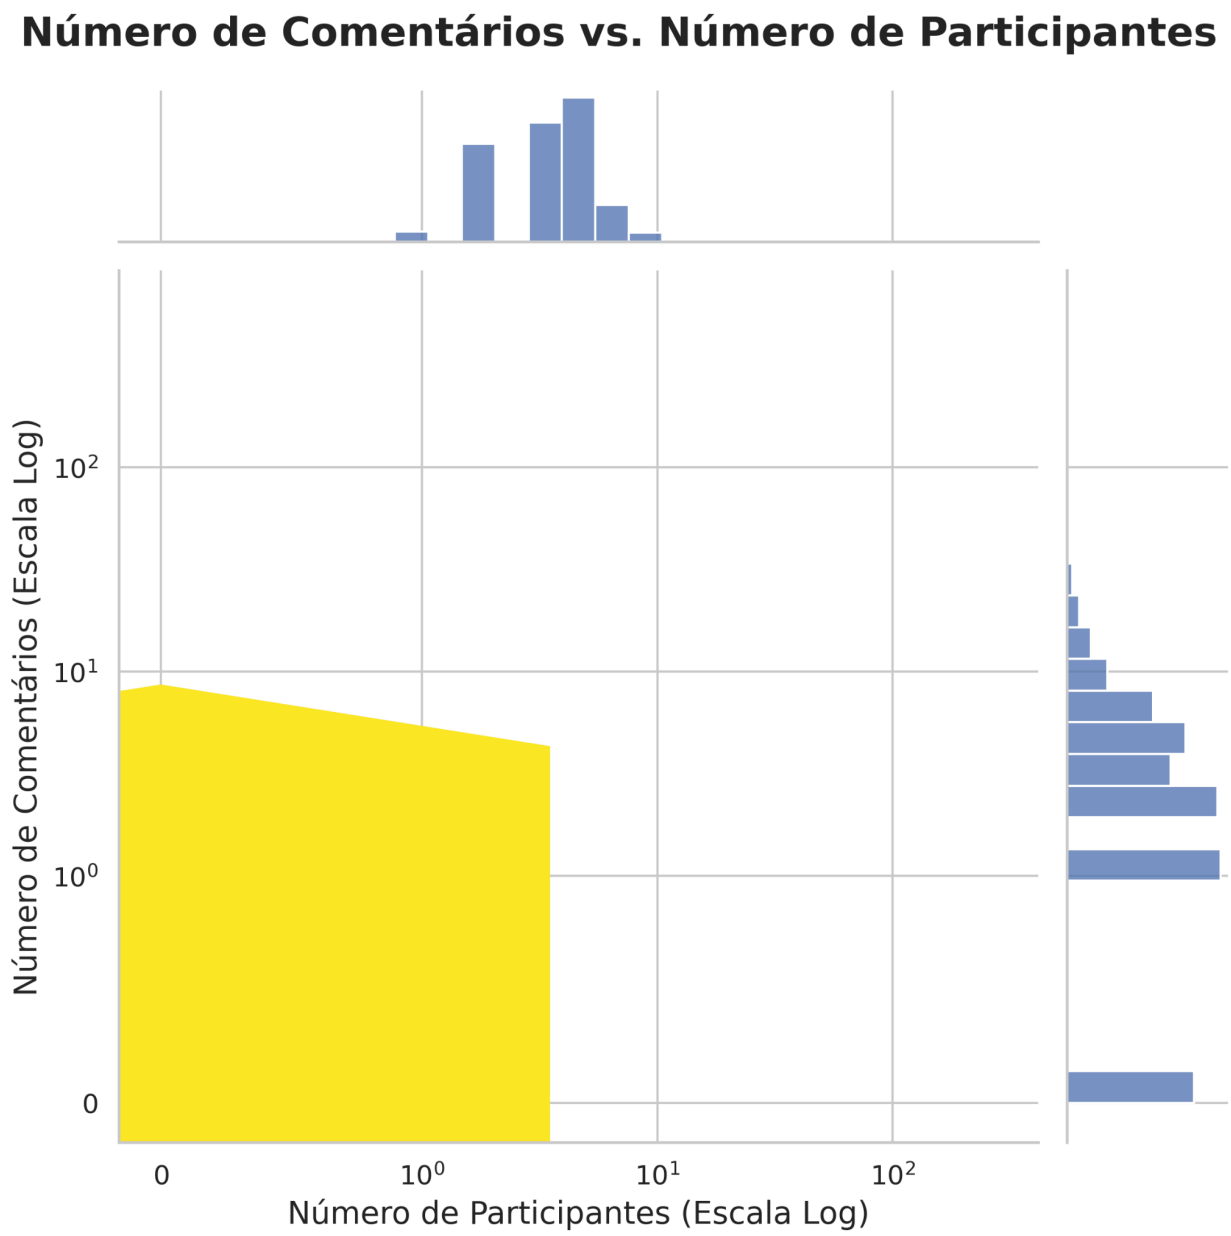

Número de Comentários vs. Tamanho da Descrição
Número de Comentários (Escala Log)
Tamanho da Descrição (Caracteres) (Escala Log)
Contagem de Pull Requests
10^0
10^1
10^2
10^3
10^4
10^5
2000
1750
1500
1250
1000
750
500
250



QP08: Relação entre Número de Participantes e Número de Comentários

Como esperado, há uma forte correlação positiva entre o número de participantes e o número de comentários. O gráfico de dispersão mostra uma tendência clara em que um aumento no número de participantes (eixo x) está associado a um aumento direto no número de comentários (eixo y). A hipótese nula H08 é, portanto, rejeitada.


Número de Comentários vs. Número de Participantes
Número de Comentários (Escala Log)
Número de Participantes (Escala Log)
Contagem de Pull Requests
10^0
10^1
10^2
1000
2000
3000
4000
5000
6000



4 Discussão

Os resultados deste estudo oferecem uma visão quantitativa sobre a dinâmica do code review em projetos de software, reforçando empiricamente certas práticas recomendadas no desenvolvimento colaborativo. A análise revela que o ciclo de vida de um Pull Request é profundamente influenciado por características mensuráveis, permitindo a identificação de perfis de PRs com maior ou menor probabilidade de sucesso.

O achado mais contundente é a forte associação entre o tempo de análise prolongado e a

rejeição de um PR. Isso sugere que um debate extenso, em vez de ser um sinal de revisão minuciosa, é frequentemente um sintoma de problemas mais profundos, como controvérsias na solução proposta, complexidade excessiva ou desalinhamento com os objetivos do projeto. Um PR que não avança rapidamente para a aprovação entra em uma zona de risco, onde a probabilidade de ser abandonado ou rejeitado aumenta consideravelmente.

Da mesma forma, um maior volume de interações (participantes e comentários) também se correlaciona com a rejeição. Isso indica que um PR "saudável" tende a ser aquele que é claro e consensual, exigindo pouca deliberação para ser aprovado. Discussões intensas, embora por vezes necessárias, são frequentemente um indicativo de que a proposta possui falhas ou não é bem-vinda, culminando em sua rejeição.

Em contraste, a qualidade da comunicação inicial, representada pelo tamanho da descrição do PR, mostrou ser um fator que contribui para o sucesso. Um desenvolvedor que investe tempo para contextualizar e justificar suas mudanças reduz a carga cognitiva dos revisores, o que facilita uma avaliação mais rápida e aumenta a probabilidade de um resultado positivo.

Por fim, o tamanho da contribuição, especialmente em número de linhas, atua como um catalisador para a complexidade do processo. Mudanças maiores tendem a gerar mais comentários, o que, por sua vez, prolonga o tempo de análise e insere o PR no ciclo de risco de rejeição.

5 Conclusão

Este estudo se propôs a caracterizar a atividade de code review no GitHub, identificando variáveis que influenciam o desfecho dos Pull Requests. A análise empírica demonstrou que o sucesso de uma contribuição de código não depende apenas de sua qualidade técnica, mas está intrinsecamente ligado à dinâmica do processo de revisão e comunicação.

Concluímos que o tempo de análise e o volume de interações são fortes preditores da rejeição de um PR , enquanto descrições detalhadas aumentam a chance de aceitação. O tamanho da contribuição, por sua vez, está diretamente correlacionado à intensidade do debate que ela irá gerar.

O resultado central reforça que a eficiência no desenvolvimento de software colaborativo depende de uma comunicação clara e da gestão proativa da complexidade. Para desenvolvedores, a implicação prática é a importância de submeter contribuições pequenas, focadas e muito bem documentadas. Para os mantenedores de projetos, os dados ressaltam a necessidade de monitorar PRs que permanecem abertos por muito tempo, pois representam um alto risco de se tornarem esforço perdido. Em suma, a qualidade de um PR reside tanto no código quanto na clareza e agilidade do processo de sua revisão.